



การวิเคราะห์ปัจจัยที่มีผลต่อยอดขาย และการนำมายปริมาณการขายของร้านอาหาร เพื่อวางแผนกลยุทธ์กระตุ้นยอดขาย

DS512/513 Data Analytics และ DS514/515 Data Science

68199160253 ชนิษฐา ลีลาเทพินทร์

68199160273 ราารัตน์ แก้วค่าไสย

68199160274 ธิติวุฒิ มลิวัลย์

10 ธันวาคม 2568

Title: การวิเคราะห์ปัจจัยที่มีผลต่อยอดขายและการทำนายปริมาณการขายของร้านอาหารเพื่อวางแผนกลยุทธ์การตั้นยอดขาย

1. Background / Problem Statement	2. Questions/Hypothesis	3. Value Propositions	4. Data Sources/Attributes
<p>Background:</p> <ul style="list-style-type: none"> ธุรกิจร้านอาหารต้องเผชิญความท้าทายในการบริหารจัดการยอดขาย การกำหนดราคา และการวางแผนโปรดิว咪ชัน ท่ามกลางปัจจัยภายนอกที่เปลี่ยนแปลง <p>Problem Statement:</p> <ul style="list-style-type: none"> ขาดเครื่องมือคาดการณ์ยอดขายที่แม่นยำ การกำหนดราคาและโปรดิว咪ชันบังไม่องัช้อมูล ไม่ทราบปัจจัยที่ส่งผลต่อยอดขายและพฤติกรรมลูกค้า 	<p>Research Questions:</p> <ol style="list-style-type: none"> ปัจจัยใดบ้างที่มีผลกระแทกต่อยอดขายของร้านอาหาร <ul style="list-style-type: none"> สภาพอากาศ โปรดิว咪ชัน และเหตุการณ์พิเศษส่งผลต่อยอดขายอย่างไร ประเภทร้านอาหารและประเภทมื้้อาหารมีความสัมพันธ์กับยอดขายหรือไม่ กลยุทธ์การกำหนดราคาและโปรดิว咪ชันมีประสิทธิภาพเพียงใด <ul style="list-style-type: none"> ความแตกต่างระหว่างราคาตลาดกับราคาขายจริงส่งผลต่อยอดขายอย่างไร โปรดิว咪ชันช่วยเพิ่มยอดขายและผลกำไรได้จริงหรือไม่ 	<ol style="list-style-type: none"> ผู้ประกอบการร้านอาหาร: เข้าใจปัจจัยที่ส่งผลต่อยอดขายและพฤติกรรมลูกค้า ช่วยในการวางแผนกลยุทธ์ราคา โปรดิว咪ชัน และการบริหารเมนูอย่างมีประสิทธิภาพ นักการตลาด: ได้ข้อมูลเชิงลึกเกี่ยวกับประสิทธิภาพของโปรดิว咪ชันและปัจจัยภายนอกที่ส่งผลต่อการตัดสินใจซื้อของลูกค้า เพื่อวางแผนแคมเปญที่ตรงเป้าหมาย 	<ul style="list-style-type: none"> Data Sources: Kaggle (Link) Restaurant Sales Report 2024-2025 Attributes: 13 Records: 10,000 Target: ปริมาณการขาย (quantity_sold) Features: ยอดขายวันก่อนหน้า (lag1), ราคาขาย (selling price), สภาพอากาศ, มีโปรดิว咪ชัน, เหตุการณ์พิเศษ (event)
5. Analysis/Model Development	6. Findings and Insights		7. Recommendation/Action and Impact
<p>1. Analysis:</p> <ul style="list-style-type: none"> - Descriptive Statistics - Correlation Analysis <p>2. Results:</p> <ul style="list-style-type: none"> - Data Visualization: Tableau - Summary Statistics <p>3. Modeling (Supervised learning)</p> <ul style="list-style-type: none"> - linear regression - regularized linear regression (ridge, lasso, elastic net) <p>4. Model evaluation: R², MAE, RMSE</p>			

Explore the data





DATA DICTIONARY

Attribute	Description	Data Type	Valid Range/Example
date	วันที่ของการขาย (รูปแบบ dd/MM/yyyy)	Date/DateTime	01/01/2024 – 01/01/2025
restaurant_id	รหัสร้านอาหาร (ตัวเลขไม่ซ้ำ)	Number/Float	1 – 50
restaurant_type	ประเภทของร้าน (Food Stall / Casual / Fine Dining)	Text	Food Stall / Casual Dining / Fine Dining
menu_item_name	ชื่อเมนูอาหารที่ขาย	Text	Kaya Toast Set / Cendol / Teh Tarik
meal_type	ประเภทมื้ออาหาร (Breakfast / Lunch / Dinner)	Text	Dinner / Lunch / Breakfast
key_ingredients_tags	วัตถุกุดิบหลักของเมนู (คั่นด้วย comma)	Text	white bread, kaya, butter, soft-boiled eggs / rice flour jelly, coconut milk, palm sugar, red beans / black tea, condensed milk, evaporated milk
typical_ingredient_cost	ต้นทุนวัตถุกุดิบโดยประมาณ	Number/Float	0.8 – 9
observed_market_price	ราคาตลาดที่สังเกตได้ของเมนู	Number/Float	1.46 – 56.29
actual_selling_price	ราคากำไรจริงให้ลูกค้า	Number/Float	1.36 – 83.09
quantity_sold	จำนวนที่ขายได้ (หน่วยเป็นงาน/หน่วย)	Number/Float	0 – 1668
has_promotion	มีโปรโมชันหรือไม่ (True/False)	Boolean	True / False
special_event	อยู่ในช่วงอีเวนต์พิเศษหรือไม่ (True/False)	Boolean	True / False
weather_condition	สภาพอากาศในวันขาย (เช่น Sunny/Rainy/Cloudy)	Text	Sunny / Cloudy / Rainy

Data:

- 10,000 records
- 13 Attributes

Types of Variables

- 11 Categorical
- 2 Continuous



DATA PREPARATION (Cleansing)

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	date	restaurant	restaurant_type	menu_item_name	meal_type	key_ingredients_tags	typical_ing	observed	actual_sell	quantity_s	has_promo	special_ev	weather_c
9983	1/1/2025	17 Food Stall	Cendol	Lunch	rice flour jelly, coconut r	15.2	38.456	46.36	336	FALSE	FALSE	Sunny	
9984	1/1/2025	29 Food Stall	Chicken Rice	Lunch	chicken, rice, ginger, ga	30.4	74.404	93.252	495	FALSE	FALSE	Sunny	
9985	1/1/2025	41 Cafe	Cendol	Lunch	rice flour jelly, coconut r	15.2	41.496	53.504	371	FALSE	FALSE	Cloudy	
9986	1/1/2025	18 Food Stall	Tandoori Chicken	Dinner	chicken, yogurt, tandoor	53.2	122.208	206.796	169	FALSE	FALSE	Sunny	
9987	1/1/2025	12 Cafe	Mushroom Soup	Dinner	mushrooms, cream, oni	26.6	110.2	127.604	131	FALSE	FALSE	Rainy	
9988	1/1/2025	6 Fine Dining	Chicken Chop	Dinner	chicken thigh, black pep	60.8	331.816	364.648	185	FALSE	FALSE	Sunny	
9989	1/1/2025	25 Fine Dining	Mushroom Soup	Dinner	mushrooms, cream, oni	26.6	142.348	229.824	40	FALSE	FALSE	Cloudy	
9990	1/1/2025	3 Cafe	Beef Rendang	Dinner	beef, coconut milk, gala	68.4	229.9	327.18	60	FALSE	FALSE	Rainy	
9991	1/1/2025	31 Food Stall	Kaya Toast Set	Breakfast	white bread, kaya, butte	21.28	47.272	71.06	635	FALSE	FALSE	Sunny	
9992	1/1/2025	3 Cafe	Spaghetti Carbonara	Dinner	spaghetti, eggs, cheese,	68.4	274.284	210.14	364	TRUE	FALSE	Rainy	
9993	1/1/2025	35 Food Stall	Char Kway Teow	Lunch	flat rice noodles, prawns	38	71.44	115.824	304	FALSE	FALSE	Cloudy	
9994	1/1/2025	49 Kopitiam	Teh Tarik	Breakfast	black tea, condensed mi	6.84	14.44	23.484	950	FALSE	FALSE	Cloudy	
9995	1/1/2025	24 Casual Dining	Cendol	Dinner	rice flour jelly, coconut r	15.2	46.892	75.468	418	FALSE	FALSE	Rainy	
9996	1/1/2025	41 Cafe	Kaya Toast Set	Breakfast	white bread, kaya, butte	21.28	64.904	88.844	660	FALSE	FALSE	Cloudy	
9997	1/1/2025	45 Food Stall	Cendol	Dinner	rice flour jelly, coconut r	15.2	33.516	33.972	588	TRUE	FALSE	Sunny	
9998	1/1/2025	44 Food Stall	Teh Tarik	Lunch	black tea, condensed mi	6.84	18.544	19.836	511	FALSE	FALSE	Rainy	
9999	1/1/2025	38 Fine Dining	Iced Lemon Tea	Dinner	black tea, lemon, sugar	9.12	45.904	52.516	442	FALSE	FALSE	Sunny	
10000	1/1/2025	3 Cafe	Cendol	Lunch	rice flour jelly, coconut r	15.2	50.16	65.056	242	FALSE	FALSE	Sunny	
10001	1/1/2025	38 Fine Dining	Iced Lemon Tea	Dinner	black tea, lemon, sugar	9.12	40.888	51.072	276	FALSE	FALSE	Cloudy	
10002													
10003	10000	10000	10000	10000	10000	10000	10000	10000	10000	10000	10000	10000	
10004													

Data:

- 10,000 records
- 13 Attributes

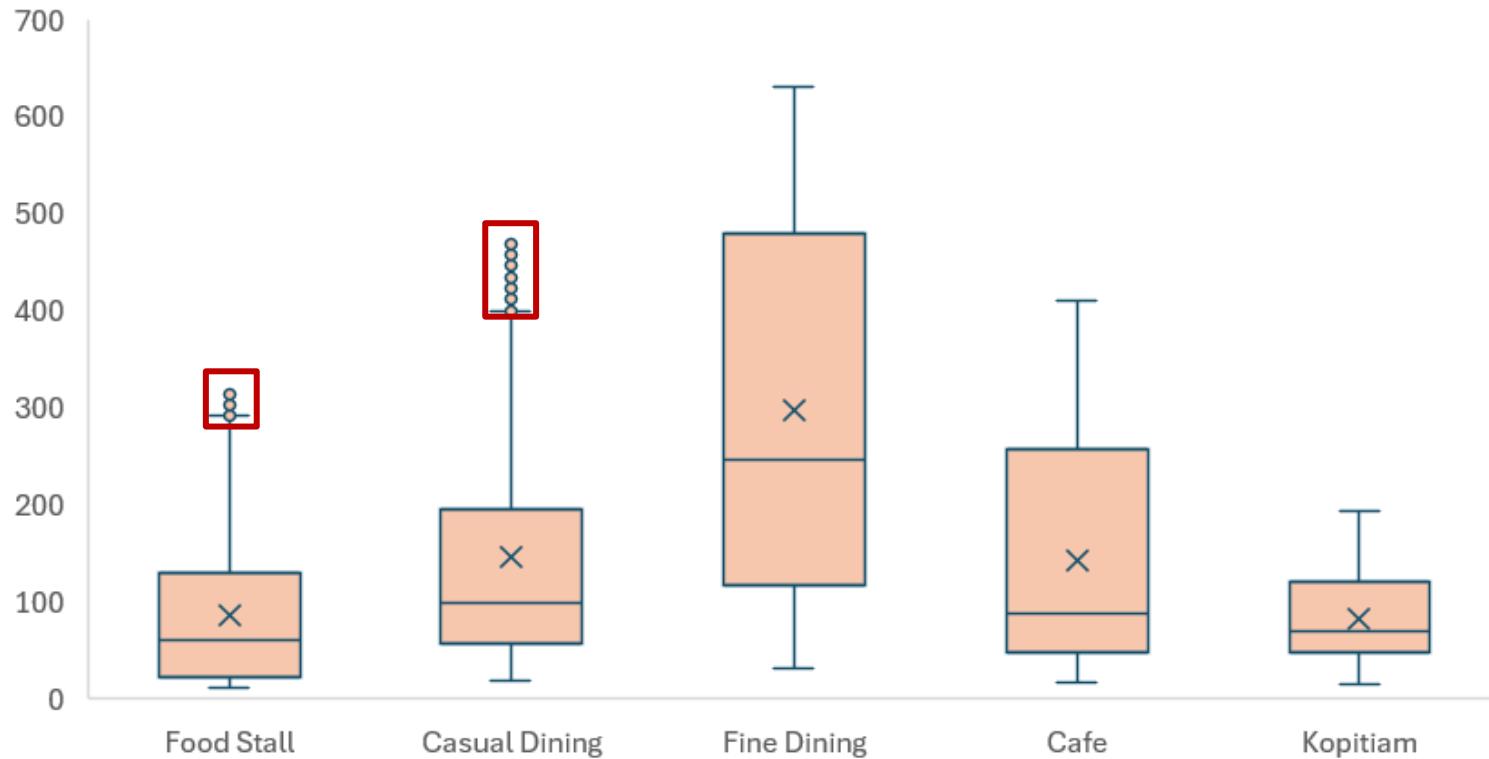
Cleansing

- Missing Value: No
- Duplicate: No
- Format: Date



DATA PREPARATION (Outlier)

Actual Selling Price By Restaurant Type



Data:

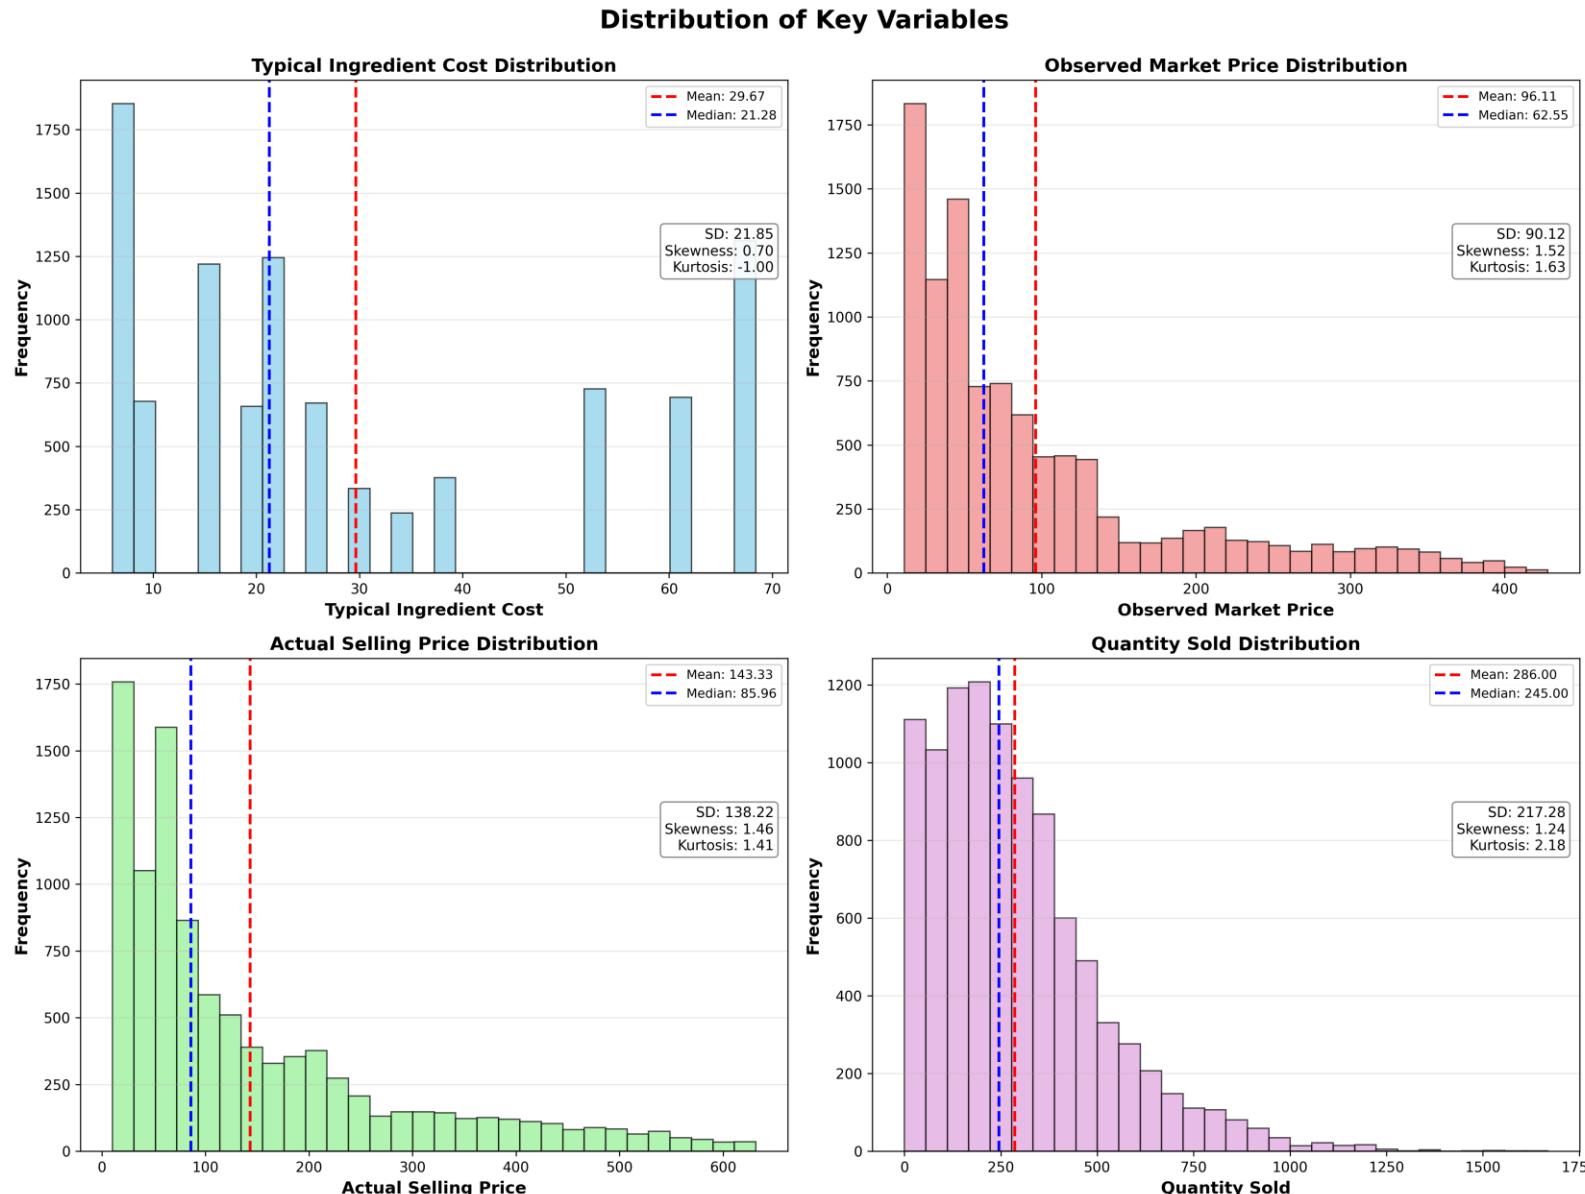
- 10,000 records
- 13 Attributes

Cleansing

- **Outlier:** Food Stall, Casual Dining (486)



EXPLORATORY DATA ANALYSIS (Histogram)



Data:

- 10,000 records
- 13 Attributes

Main Findings

- **Typical Ingredient Cost:**
ค่าเฉลี่ย 29.67 บาท กระจายตัวที่ 21.28 บาท
มีการกระจายแบบ right-skewed
- **Observed Market Price:**
ค่าเฉลี่ย 96.11 บาท กระจายตัวที่ 62.55 บาท
มีความแปรปรวนสูง ($SD = 90.12$)
- **Actual Selling Price:**
ค่าเฉลี่ย 143.33 บาท กระจายตัวที่ 85.96 บาท
ราคาขายสูงกว่าราคาต้นทุนเฉลี่ย ~49%
- **Quantity Sold:**
ค่าเฉลี่ย 286 หน่วย กระจายตัวที่ 245 หน่วย มี
บางวันที่ขายได้สูงสุดถึง 1,668 หน่วย



EXPLORATORY DATA ANALYSIS (Correlation)

	<i>typical_ingredient_cost</i>	<i>observed_market_price</i>	<i>actual_selling_price</i>	<i>quantity_sold</i>
<i>typical_ingredient_cost</i>	1.000			
<i>observed_market_price</i>	0.887	1.000		
<i>actual_selling_price</i>	0.888	0.952	1.000	
<i>quantity_sold</i>	-0.535	-0.464	-0.548	1.000

- ข้อสังเกต: ราคาก็จะมีความสัมพันธ์เชิงลบกับยอดขาย แสดงว่าลูกค้ามีความอ่อนไหวต่อราคา (price sensitive)

Data:

- 10,000 records
- 13 Attributes

Main Findings

Strong Correlation

- Observed Market Price ↔ Actual Selling Price** ($r = 0.948$) – ราคากลางและราคายield จึงมีความสัมพันธ์สูงมาก
- Typical Ingredient Cost ↔ Actual Selling Price** ($r = 0.894$) – ต้นทุนวัตถุดิบสัมพันธ์กับราคายield
- Typical Ingredient Cost ↔ Observed Market Price** ($r = 0.888$) - ต้นทุนวัตถุดิบสัมพันธ์กับราคากลาง

Medium Correlation

- Actual Selling Price ↔ Quantity Sold** ($r = -0.537$) - ราคายield สูง ยอดขายลดลง
- Typical Ingredient Cost ↔ Quantity Sold** ($r = -0.534$) - ต้นทุนสูง ยอดขายลดลง
- Observed Market Price ↔ Quantity Sold** ($r = -0.460$) - ราคากลางสูง ยอดขายลดลง

Dashboard



Restaurant Dashboard

REVENUE

1,036K

(Baht)

COST

219K

(Baht)

QUANTITY SOLD

6K

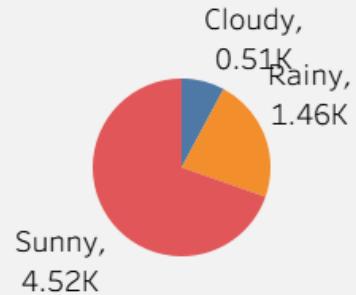
(Items)

GROSS PROFIT

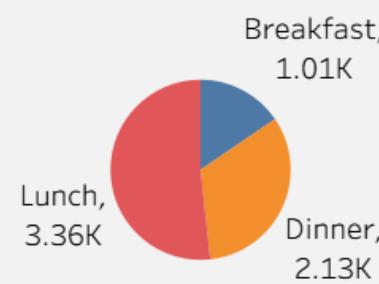
817K

(Baht)

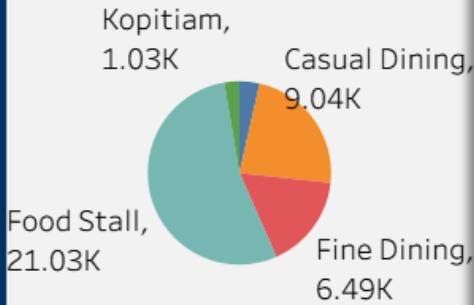
Quantity Sold By Weather



Quantity Sold By Meal Type

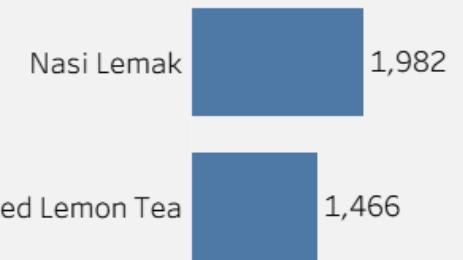


Quantity by Restaurant Type

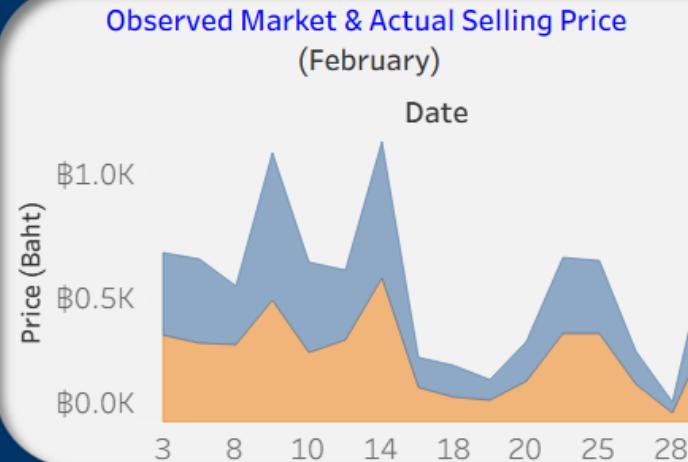


Menu

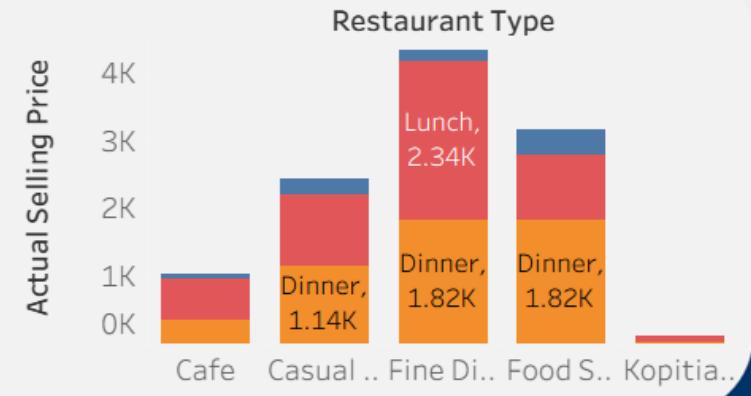
Menu Item Name



Observed Market & Actual Selling Price
(February)



Revenue By Restaurant & Meal Type



Month of Date

February

Restaurant Type

Fine Dining

Promotion

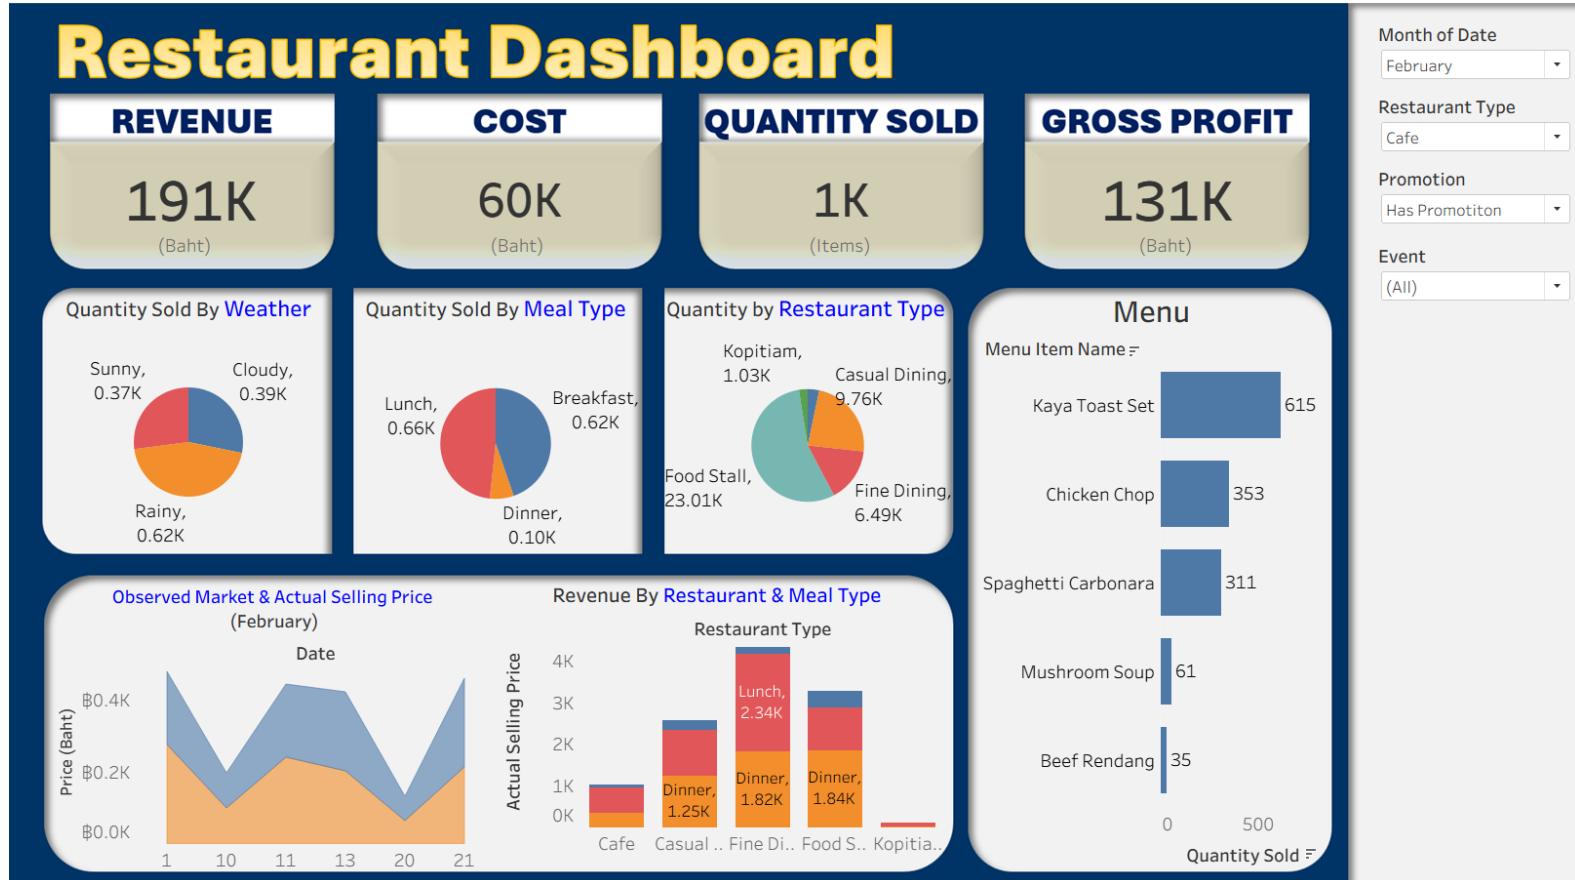
Has Promotion

Event

Hasn't Special Event



DASHBOARD



Data:

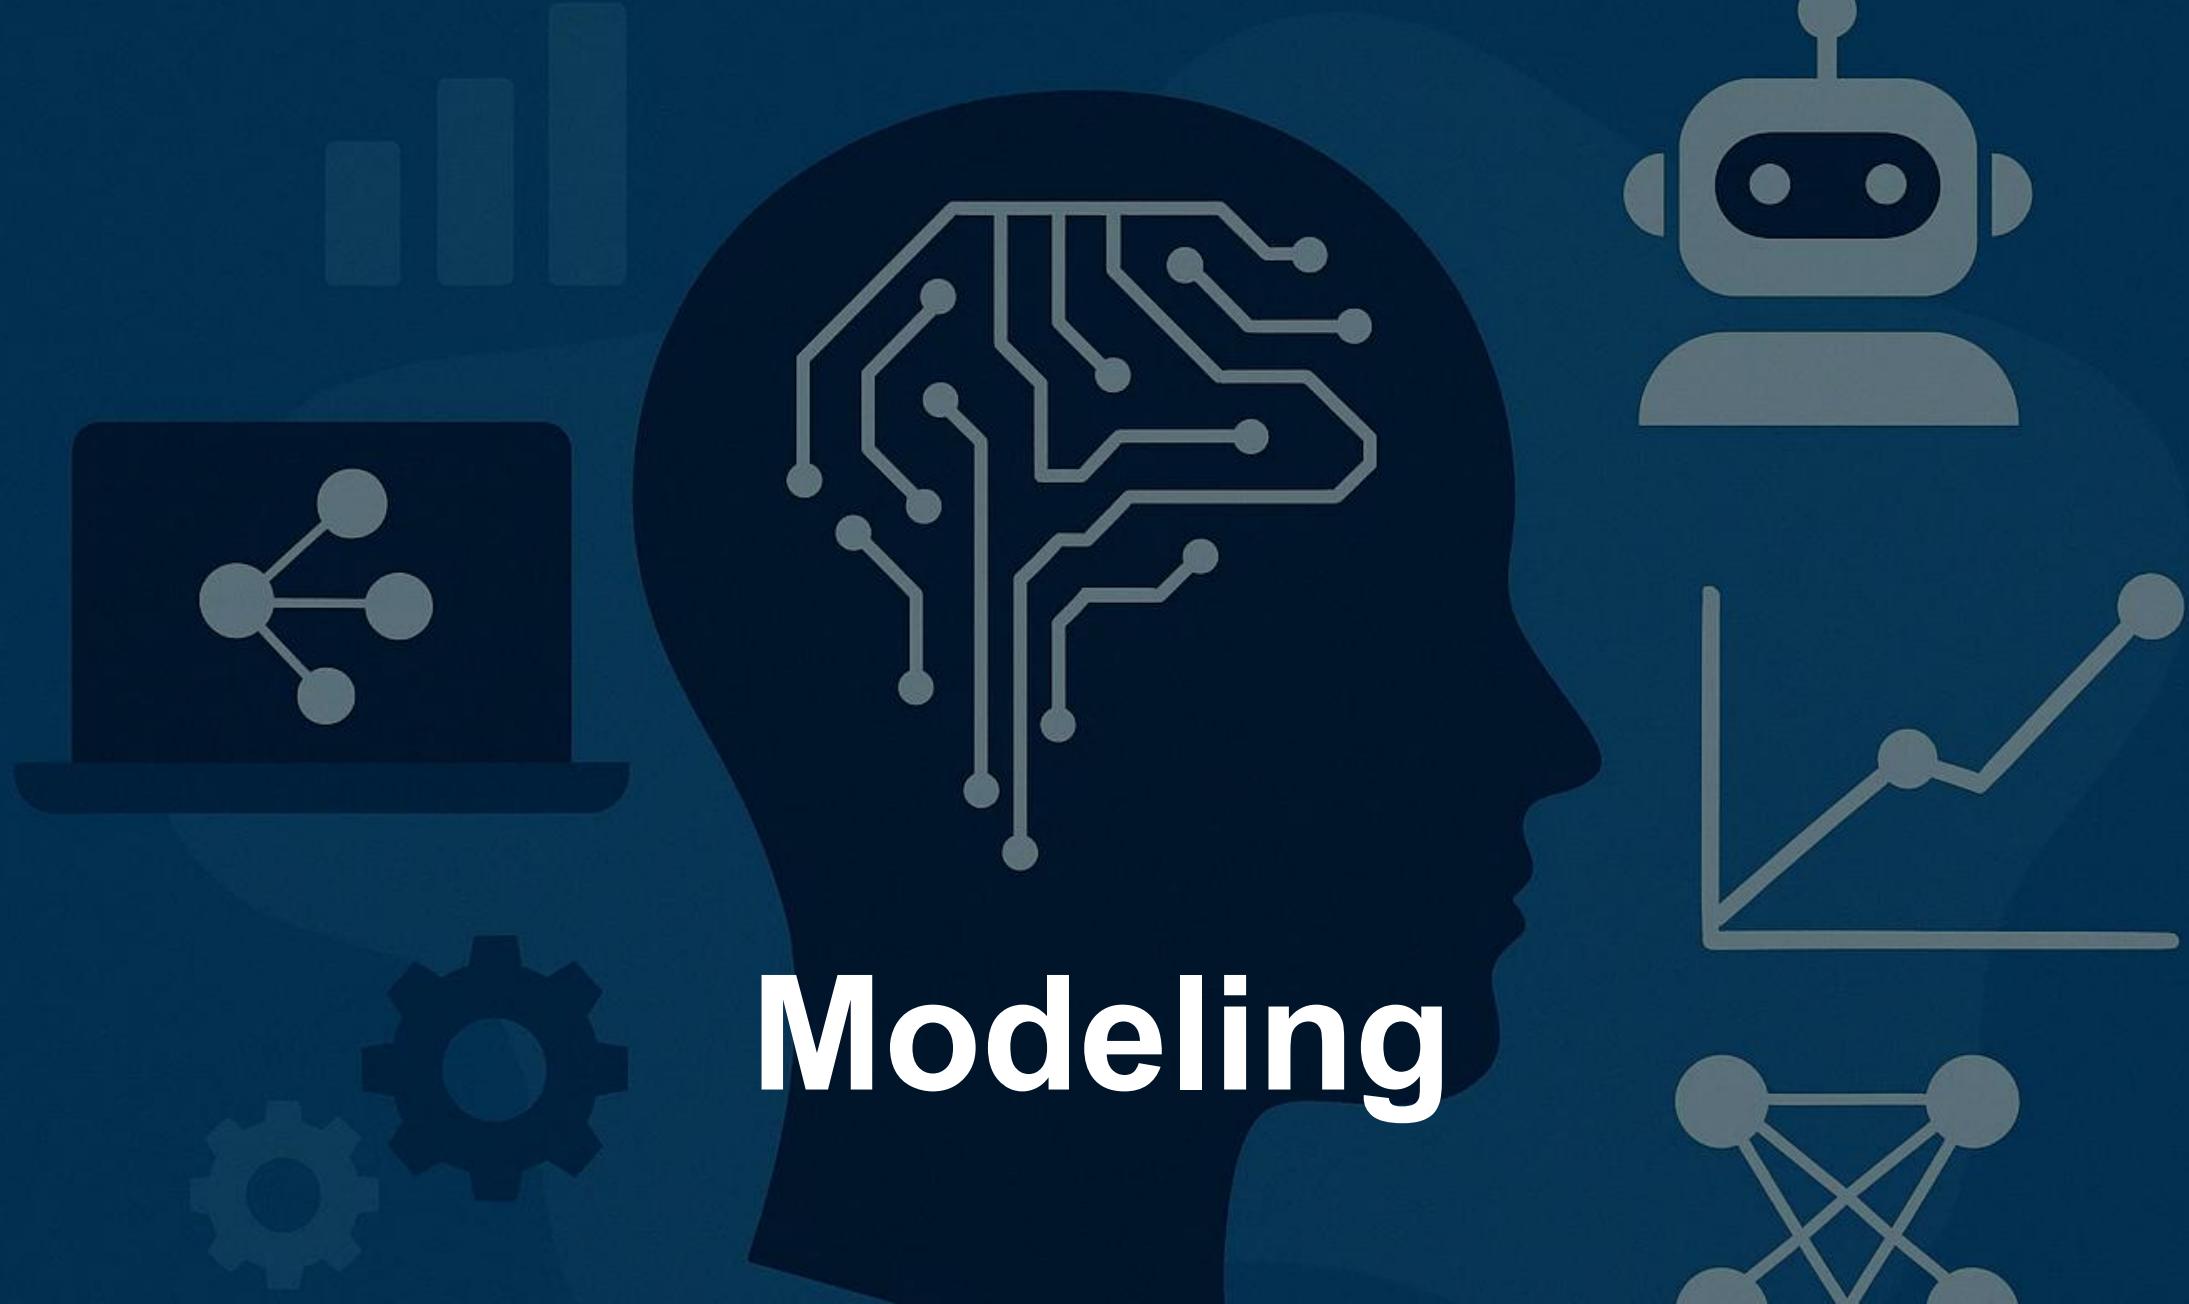
- 10,000 records
- 13 Attributes

Main Findings

จาก Dashboard จะพบว่า

- สภาพอากาศ:** มีผลต่อยอดขาย โดยในวันที่อากาศ Sunny จะขายได้มากที่สุด
- ประเภทร้านอาหารและประเภทมื้ออาหาร:** ประเภทร้าน Finding มียอดขายดีที่สุด และในแต่ละประเภทมื้อกลางวันเป็นมื้อที่ทำยอดขายได้ดีที่สุด
- โปรโมชั่น:** จะพบว่าวันที่มีโปรโมชั่นจะช่วยเพิ่มยอดขายได้มากขึ้นกว่าวันปกติ

Modeling





Data Cleaning

Import data and check “Missing Data”

```
# import numpy, pandas, matplotlib, seaborn
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# read csv file
data = pd.read_csv('/content/drive/MyDrive/DS514.csv')
data.head()

# check data.info
data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 13 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   date             10000 non-null   object 
 1   restaurant_id    10000 non-null   int64  
 2   restaurant_type  10000 non-null   object 
 3   menu_item_name   10000 non-null   object 
 4   meal_type        10000 non-null   object 
 5   key_ingredients_tags 10000 non-null   object 
 6   typical_ingredient_cost 10000 non-null   float64
 7   observed_market_price 10000 non-null   float64
 8   actual_selling_price 10000 non-null   float64
 9   quantity_sold    10000 non-null   int64  
 10  has_promotion    10000 non-null   bool   
 11  special_event    10000 non-null   bool   
 12  weather_condition 10000 non-null   object 
dtypes: bool(2), float64(3), int64(2), object(6)
memory usage: 879.0+ KB

# check data is NULL
data.isnull().sum()

date          0
restaurant_id 0
restaurant_type 0
menu_item_name 0
meal_type      0
key_ingredients_tags 0
typical_ingredient_cost 0
observed_market_price 0
actual_selling_price 0
quantity_sold 0
has_promotion 0
special_event 0
weather_condition 0
dtype: int64
```

- Import important library
- Import data from csv file
- Check “Missing Data” → No “NULL” value
- Data: 10,000 records / 13 columns



Data Cleaning

Check and change data type

```
# change date from 'object' to 'date'
data['date'] = pd.to_datetime(data['date'])
data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 13 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   date             10000 non-null   datetime64[ns]
 1   restaurant_id    10000 non-null   int64  
 2   restaurant_type  10000 non-null   object  
 3   menu_item_name   10000 non-null   object  
 4   meal_type        10000 non-null   object  
 5   key_ingredients_tags  10000 non-null   object  
 6   typical_ingredient_cost  10000 non-null   float64 
 7   observed_market_price  10000 non-null   float64 
 8   actual_selling_price  10000 non-null   float64 
 9   quantity_sold    10000 non-null   int64  
 10  has_promotion    10000 non-null   bool   
 11  special_event    10000 non-null   bool   
 12  weather_condition 10000 non-null   object  
dtypes: bool(2), datetime64[ns](1), float64(3), int64(2), object(5)
memory usage: 879.0+ KB
```

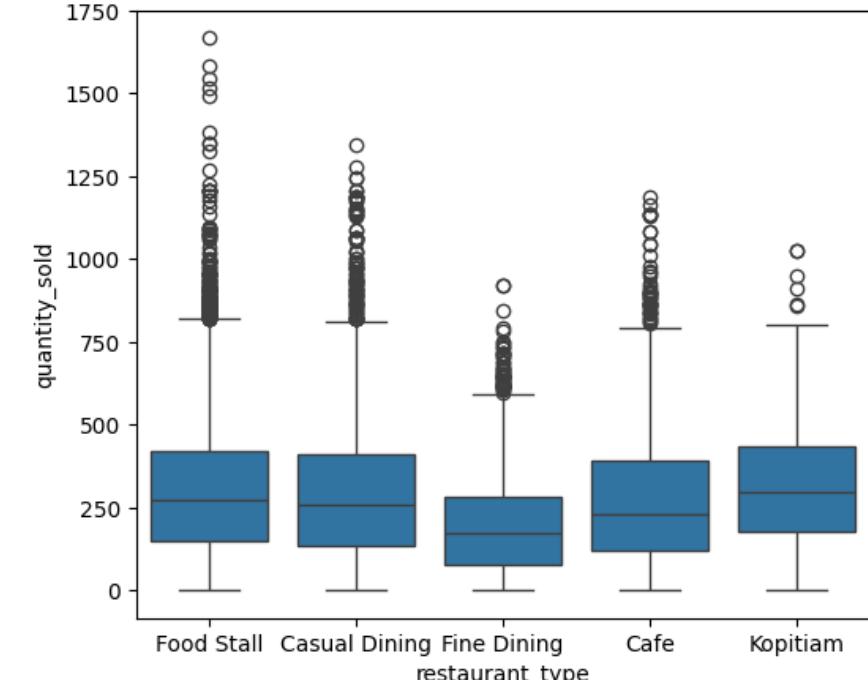
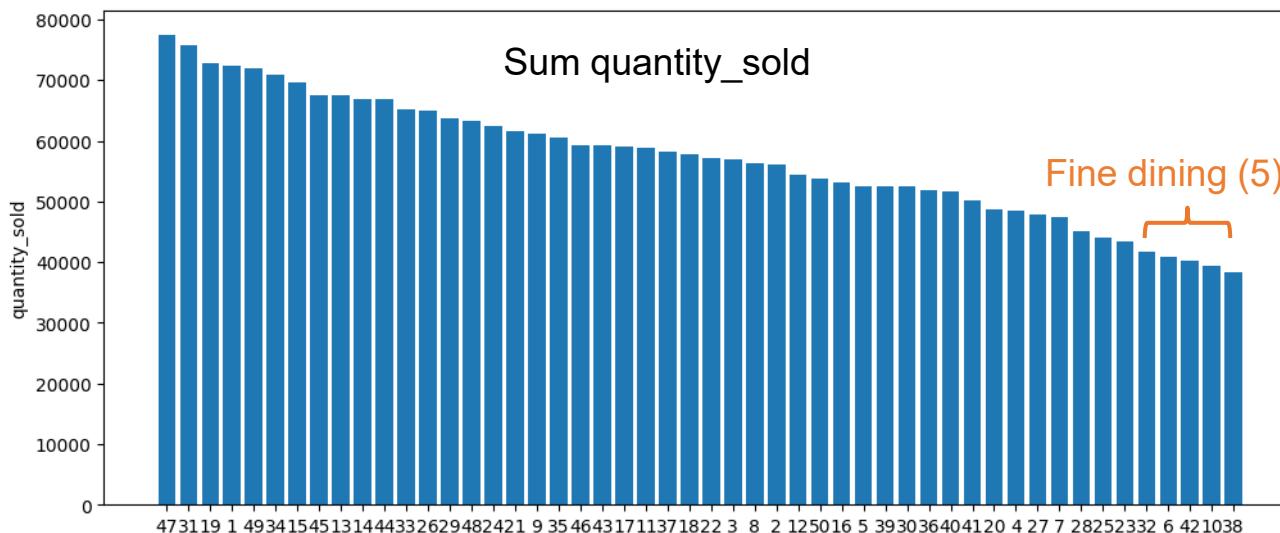
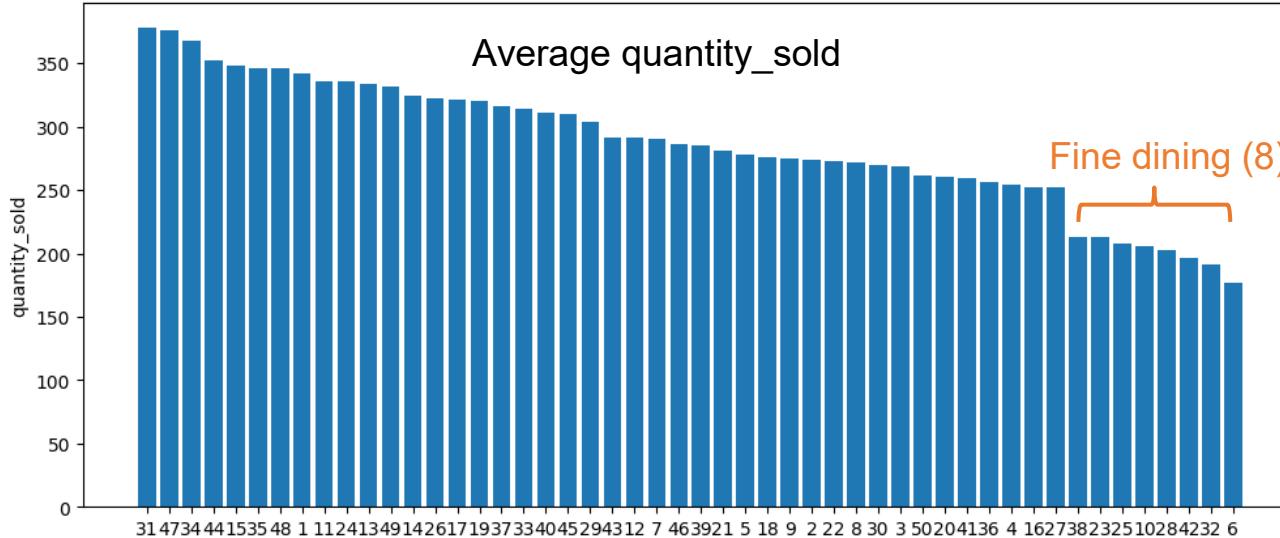
```
# change restaurant_id from 'int' to 'object'
data['restaurant_id'] = data['restaurant_id'].astype(str)
data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 13 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   date             10000 non-null   datetime64[ns]
 1   restaurant_id    10000 non-null   object  
 2   restaurant_type  10000 non-null   object  
 3   menu_item_name   10000 non-null   object  
 4   meal_type        10000 non-null   object  
 5   key_ingredients_tags  10000 non-null   object  
 6   typical_ingredient_cost  10000 non-null   float64 
 7   observed_market_price  10000 non-null   float64 
 8   actual_selling_price  10000 non-null   float64 
 9   quantity_sold    10000 non-null   int64  
 10  has_promotion    10000 non-null   bool   
 11  special_event    10000 non-null   bool   
 12  weather_condition 10000 non-null   object  
dtypes: bool(2), datetime64[ns](1), float64(3), int64(1), object(6)
memory usage: 879.0+ KB
```

- Change date from “object” to “datetime64[ns]”
- Change restaurant_id from “int64” to “object”



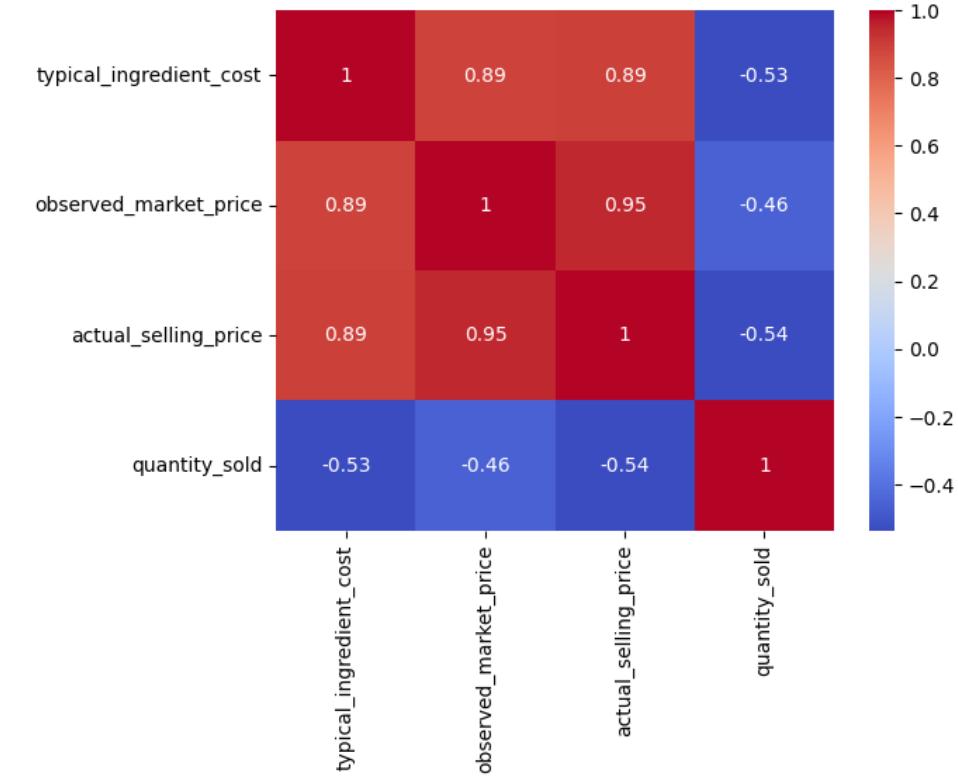
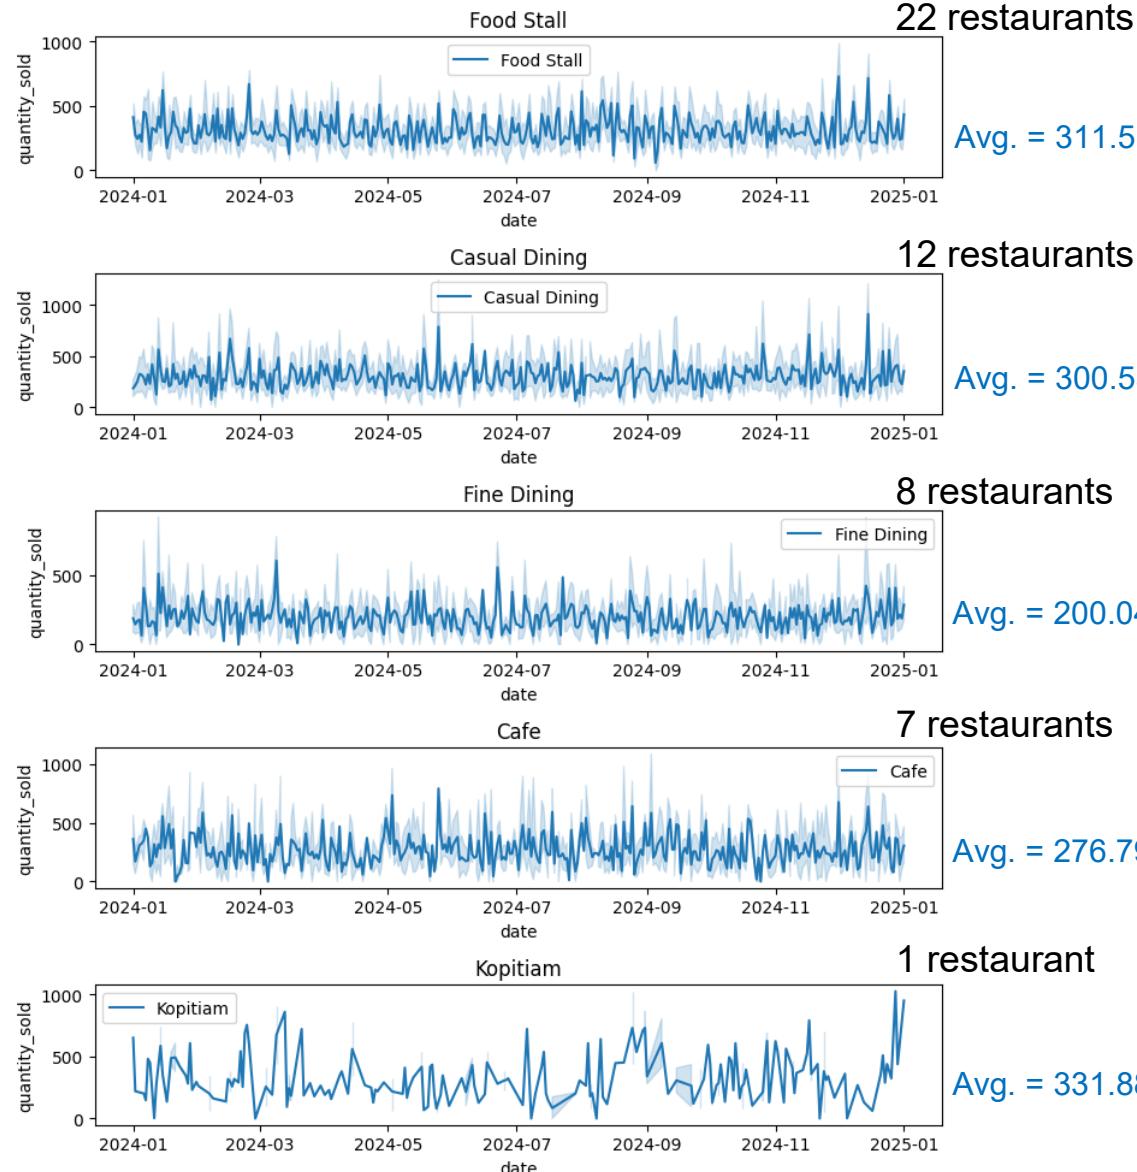
EDA 1 – Overview of Quantity Sold



- Average and sum quantity_sold show that fine dining ranks the lowest among the 50 restaurants.
- Box-whisker plot shows that the median value for fine dining is lower than the other four restaurant types.



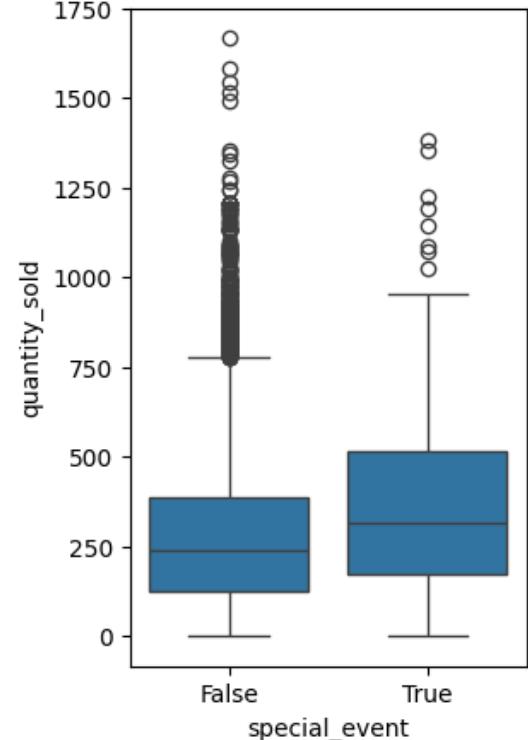
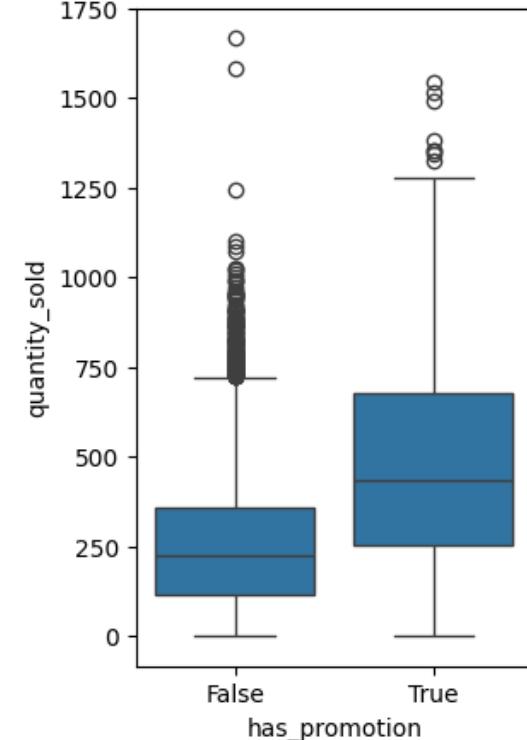
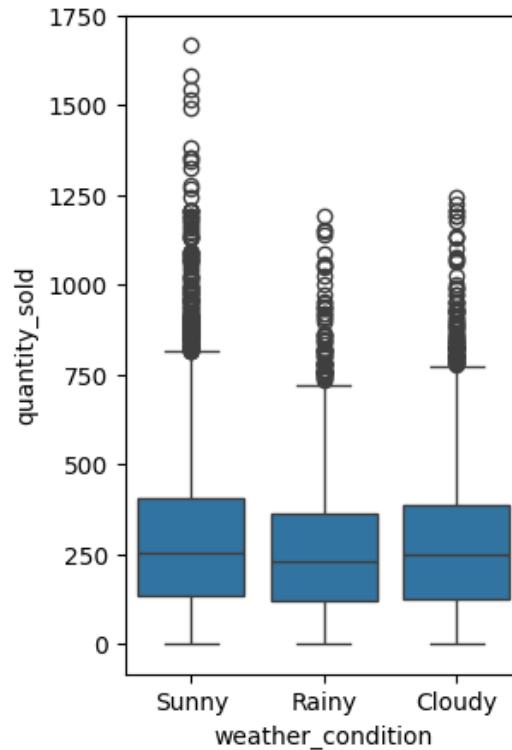
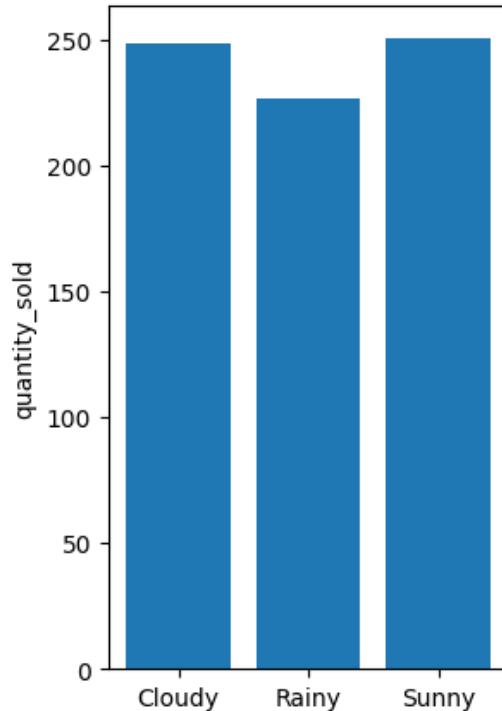
EDA 2 – Analysis of 1-year Trend and Correlation



- No obvious trend or pattern is observed in the time-series plot, but the annual average quantity_sold for fine dining is significantly lower than that of others.
- Correlation analysis indicates that cost, market_price, and selling_price are strongly positively correlated. However, quantity_sold shows a moderate negative correlation with others.



EDA 3 – Effects of Weather/Promotion/Event



- The average quantity_sold on sunny (251) and cloudy (249) days is higher than on rainy days (227).
- However, the difference is very small, which makes it difficult to observe in the box-whisker plot.

- The average quantity_sold on promotion days (482) is higher than on non-promotion days (251).
- Similarly, the average quantity_sold on days with special events (363) is also higher than on days without events (282).



Data and Feature Selection

Select only the last five restaurants (`restaurant_id = '32' '6' '42' '10' '38'`) to build the model for predicting `quantity_sold`, and then use the model to identify ways to improve sales performance.

```
# Prepare more data for modeling
# focus on restaurant_id '32' '6' '42' '10' '38'
model_data = data[data['restaurant_id'].isin(['32', '6', '42', '10', '38'])]
model_data.head()
```

		date	restaurant_id	restaurant_type	menu_item_name	meal_type	key_ingredients_tags	typical_ingredient_cost	observed_market_price	actual_selling_price	quantity_sold	has_promotion	special_event
4	2024-01-01	32	Fine Dining	Spaghetti Carbonara	Lunch	spaghetti, eggs, cheese, beef bacon, black pepper	68.4	306.280	422.104	262	False		
23	2024-01-01	42	Fine Dining	Spaghetti Carbonara	Dinner	spaghetti, eggs, cheese, beef bacon, black pepper	68.4	308.864	431.832	143	False		
34	2024-01-02	6	Fine Dining	Mushroom Soup	Dinner	mushrooms, cream, onion, garlic, vegetable broth	26.6	114.608	222.528	30	False		
36	2024-01-02	42	Fine Dining	Nasi Lemak	Lunch	rice, coconut milk, sambal, anchovies, egg, pe...	19.0	102.372	82.764	238	True		
40	2024-01-02	42	Fine Dining	Beef Rendang	Dinner	beef, coconut milk, galangal, lemongrass, spic...	68.4	390.488	508.288	126	False		

0	restaurant_id	0
10	192	0
32	218	0
38	180	0
42	205	0
6	232	0

Total 1,027 records

numeric

categorical

Quantity_sold = f(lag1, actual_selling_price, weather_condition, has_promotion, special_event)

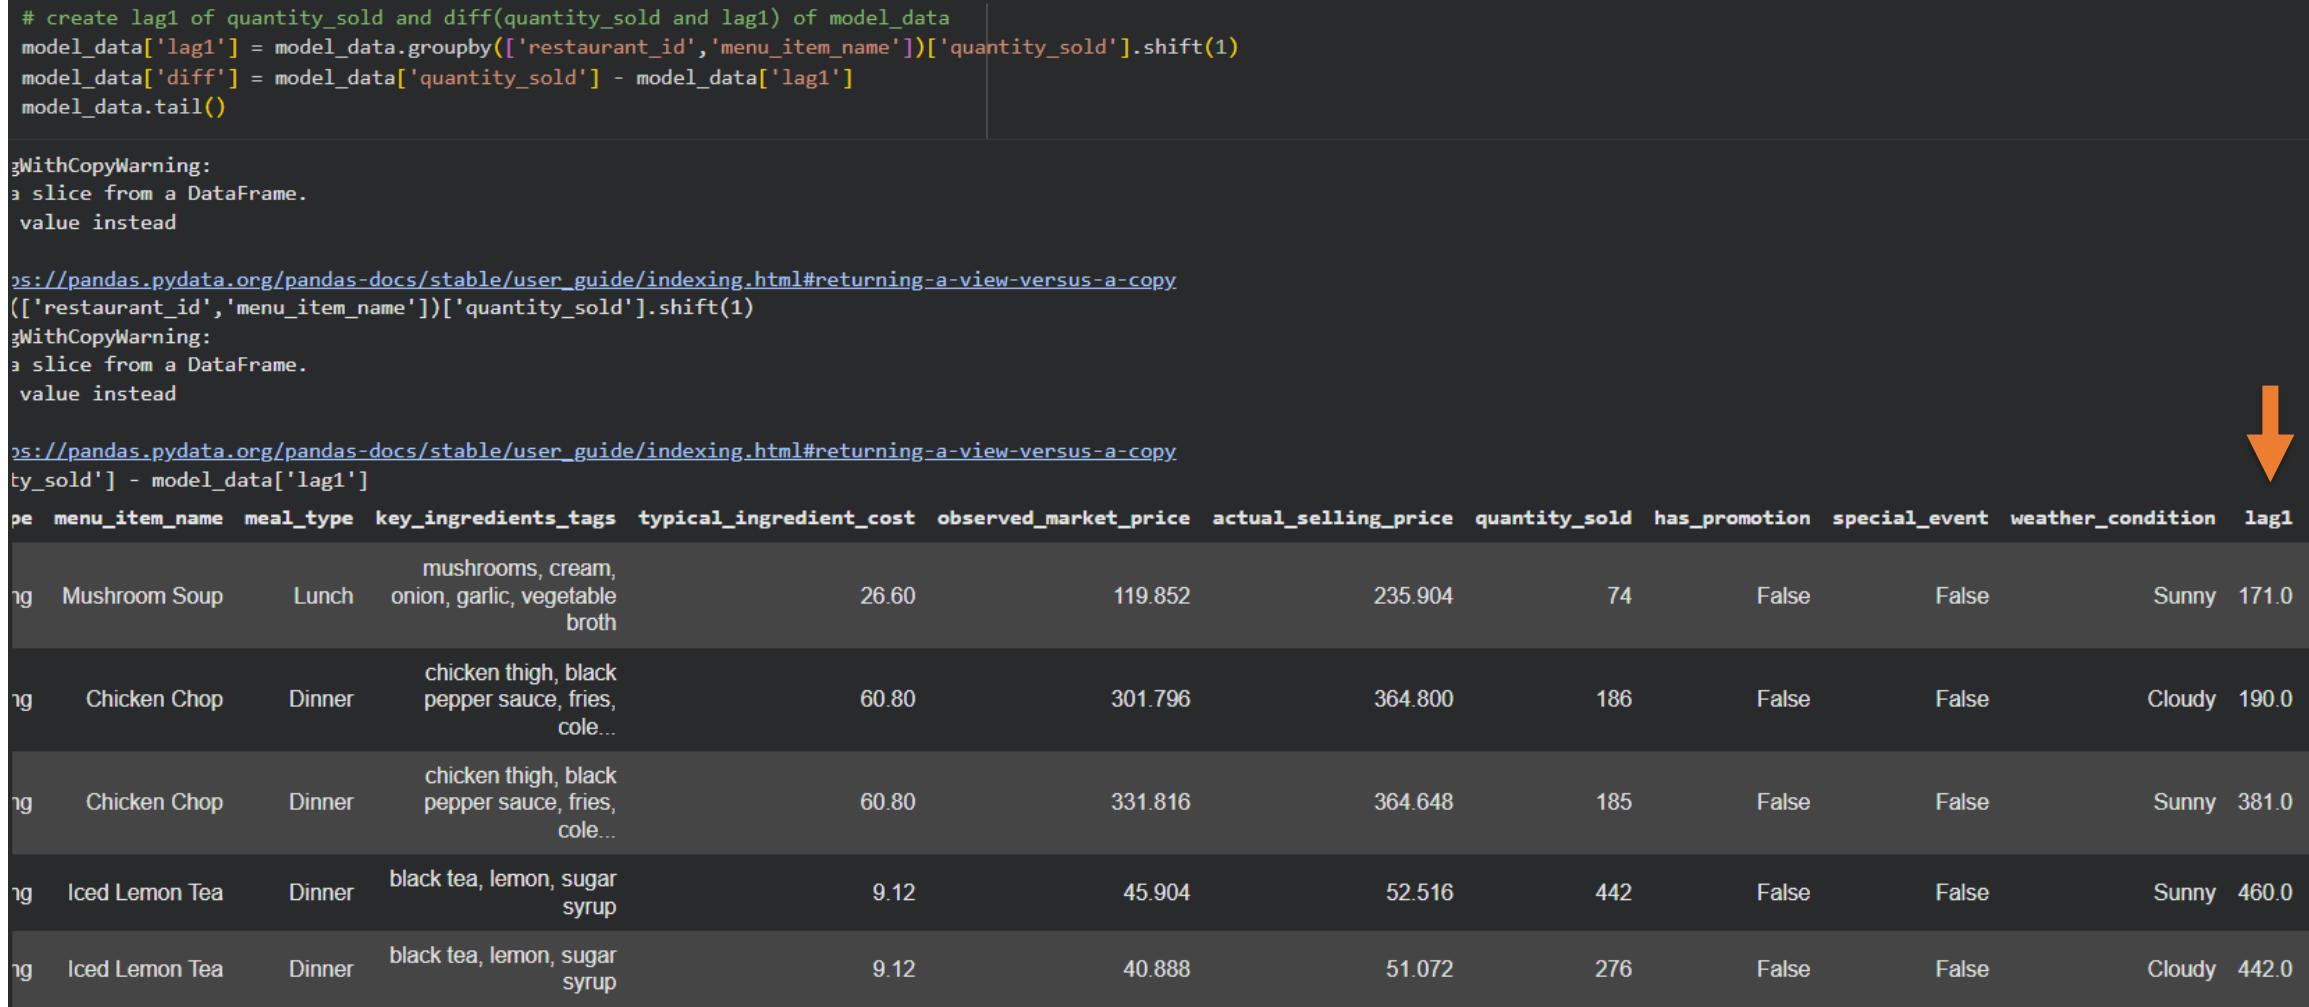
Target

Feature



Data and Feature Selection

Create 'lag1' as another feature for modeling



```
# create lag1 of quantity_sold and diff(quantity_sold and lag1) of model_data
model_data['lag1'] = model_data.groupby(['restaurant_id', 'menu_item_name'])['quantity_sold'].shift(1)
model_data['diff'] = model_data['quantity_sold'] - model_data['lag1']
model_data.tail()

WithCopyWarning:
a slice from a DataFrame.
value instead

ps://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
(['restaurant_id','menu_item_name'])['quantity_sold'].shift(1)
WithCopyWarning:
a slice from a DataFrame.
value instead

ps://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
ty_sold'] - model_data['lag1']

   restaurant_id menu_item_name meal_type key_ingredients_tags typical_ingredient_cost observed_market_price actual_selling_price quantity_sold has_promotion special_event weather_condition lag1
0      1000000000    Mushroom Soup       Lunch      mushrooms, cream,          26.60             119.852            235.904           74        False       False        Sunny     171.0
1      1000000001    Chicken Chop      Dinner    chicken thigh, black          60.80             301.796            364.800          186        False       False      Cloudy     190.0
2      1000000002    Chicken Chop      Dinner    chicken thigh, black          60.80             331.816            364.648          185        False       False        Sunny     381.0
3      1000000003   Iced Lemon Tea      Dinner  black tea, lemon, sugar          9.12              45.904            52.516           442        False       False        Sunny     460.0
4      1000000004   Iced Lemon Tea      Dinner  black tea, lemon, sugar          9.12              40.888            51.072           276        False       False      Cloudy     442.0
```

	restaurant_id	menu_item_name	meal_type	key_ingredients_tags	typical_ingredient_cost	observed_market_price	actual_selling_price	quantity_sold	has_promotion	special_event	weather_condition	lag1
0	1000000000	Mushroom Soup	Lunch	mushrooms, cream, onion, garlic, vegetable broth	26.60	119.852	235.904	74	False	False	Sunny	171.0
1	1000000001	Chicken Chop	Dinner	chicken thigh, black pepper sauce, fries, cole...	60.80	301.796	364.800	186	False	False	Cloudy	190.0
2	1000000002	Chicken Chop	Dinner	chicken thigh, black pepper sauce, fries, cole...	60.80	331.816	364.648	185	False	False	Sunny	381.0
3	1000000003	Iced Lemon Tea	Dinner	black tea, lemon, sugar syrup	9.12	45.904	52.516	442	False	False	Sunny	460.0
4	1000000004	Iced Lemon Tea	Dinner	black tea, lemon, sugar syrup	9.12	40.888	51.072	276	False	False	Cloudy	442.0



Data and Feature Selection

```
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LinearRegression, Ridge, Lasso, ElasticNet
from sklearn.metrics import r2_score, mean_absolute_error, root_mean_squared_error

# --- 1. Feature and Target Definition ---

# Define the target variable (y) and the predictor variables (X)
X = model_data[['lag1', 'actual_selling_price', 'weather_condition', 'has_promotion', 'special_event']]
y = model_data['quantity_sold']

# Remove NULL value from lag1
X = X.dropna()
y = y[X.index]

# Split data into training and testing sets (80/20 split)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, shuffle=False)

# shuffle=False is crucial for time-series data to maintain chronological order

# Define feature types for the ColumnTransformer
numerical_features = ['lag1', 'actual_selling_price']
categorical_features = ['weather_condition', 'has_promotion', 'special_event']

# summary data_size of X_train, X_test, y_train, y_test
print("X_train size:", X_train.shape)
print("X_test size:", X_test.shape)
print("y_train size:", y_train.shape)
print("y_test size:", y_test.shape)

X_train size: (800, 5)
X_test size: (201, 5)
y_train size: (800,)
y_test size: (201,)
```

Import library

Set “features” and “target”

Remove “NULL” value of lag1

Train/test split (80/20)

Define numerical features / categorical features

Check size of data



Data Pre-processing / Linear Regression

```
# --- 2. Data Preprocessing Pipeline (Scaling and Encoding) ---  
  
# Create the preprocessing pipeline using ColumnTransformer  
# Apply Standard Scaling to numerical features  
# Apply One-Hot Encoding to categorical features (handle_unknown='ignore' prevents error on unseen category)  
  
preprocessor = ColumnTransformer(  
    transformers=[  
        ('num', StandardScaler(), numerical_features),  
        ('cat', OneHotEncoder(handle_unknown='ignore', sparse_output=False, drop='first'), categorical_features)  
    ],  
    remainder='passthrough' # Keep any columns not specified (if any)  
)
```

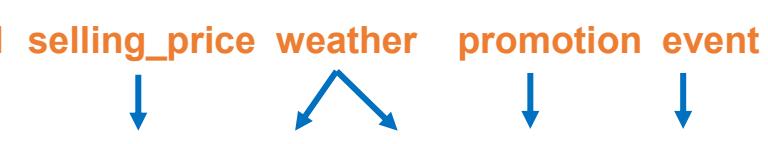
```
# --- 3. Model 1: Baseline Linear Regression ---  
  
# Create the full pipeline for Linear Regression  
lr_pipeline = Pipeline(steps=[('preprocessor', preprocessor),  
                            ('regressor', LinearRegression())])  
  
print("--- Baseline Linear Regression ---")  
lr_pipeline.fit(X_train, y_train)  
lr_predictions = lr_pipeline.predict(X_test)  
print('Coefficients:', lr_pipeline.named_steps['regressor'].coef_)  
print('Intercept:', lr_pipeline.named_steps['regressor'].intercept_)  
print("R2 Score:", r2_score(y_test, lr_predictions))  
print("MAE:", mean_absolute_error(y_test, lr_predictions))  
print("RMSE:", root_mean_squared_error(y_test, lr_predictions))  
  
--- Baseline Linear Regression ---  
Coefficients: [ 37.02 -62.21  14.57 13.10  86.55 97.70 ]  
97.70211191]  
Intercept: 163.90107045745583  
R2 Score: 0.4315164663470321  
MAE: 96.96116652820474  
RMSE: 127.86589616291008
```

Pre-processing

Numerical features -> Standard Scaler
Categorical features -> One-Hot Encoder

Pipeline = preprocessor + linear regression

Linear Regression ↓ ↓ ↗ ↓
Coefficients: [37.02 -62.21 14.57 13.10 86.55 97.70]
Intercept: 163.90
R2 Score: 0.4315
MAE: 96.96
RMSE: 127.86





Regularized Linear Regression (polynomial features)

```
# --- 4. Model 2 Ridge Regression with polynomial feature ---

from sklearn.preprocessing import PolynomialFeatures

polynomial_ridge_pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('polynomialfeatures', PolynomialFeatures()), # Placeholder, degree will be tuned
    ('regressor', Ridge())
])

param_grid = {
    # Alpha values for Ridge regularization (log scale for better searching)
    'regressor_alpha': np.logspace(-6, 3, 10),
    # Polynomial degrees to test (1 to 10)
    'polynomialfeatures_degree': np.arange(1, 11)
}

print("--- Ridge Regression with Polynomial Features Tuning ---")
grid_search = GridSearchCV(
    polynomial_ridge_pipeline,
    param_grid=param_grid,
    cv=5,
    scoring='r2'
)

grid_search.fit(X_train, y_train)

Ridge_best_estimator = grid_search.best_estimator_
Ridge_predictions = Ridge_best_estimator.predict(X_test)

best_params = grid_search.best_params_
best_degree = best_params['polynomialfeatures_degree']
best_alpha = best_params['regressor_alpha']

# Evaluation
r2_train = r2_score(y_train, Ridge_best_estimator.predict(X_train))
r2_test = r2_score(y_test, Ridge_predictions)
mae_train = mean_absolute_error(y_train, Ridge_best_estimator.predict(X_train))
mae_test = mean_absolute_error(y_test, Ridge_predictions)
rmse_train = root_mean_squared_error(y_train, Ridge_best_estimator.predict(X_train))
rmse_test = root_mean_squared_error(y_test, Ridge_predictions)
```

Pipeline = preprocessor + polynomial feature + Ridge/Lasso/Elastic net

Hyperparameter tuning (param_grid)

Ridge/Lasso/Elastic net	polynomial degree = 1 to 10
Ridge/Lasso/Elastic net	$\alpha = 10^{-6}$ to 1000
Elastic net	l1 ratio = 0 to 1

GridSearchCV = pipeline + param_grid + cv = 5 + scoring 'r2'

Find the best hyperparameters (polynomial degree, α , l1 ratio)

Evaluation

R2, MAE, RMSE



Results from Models

--- Ridge ---

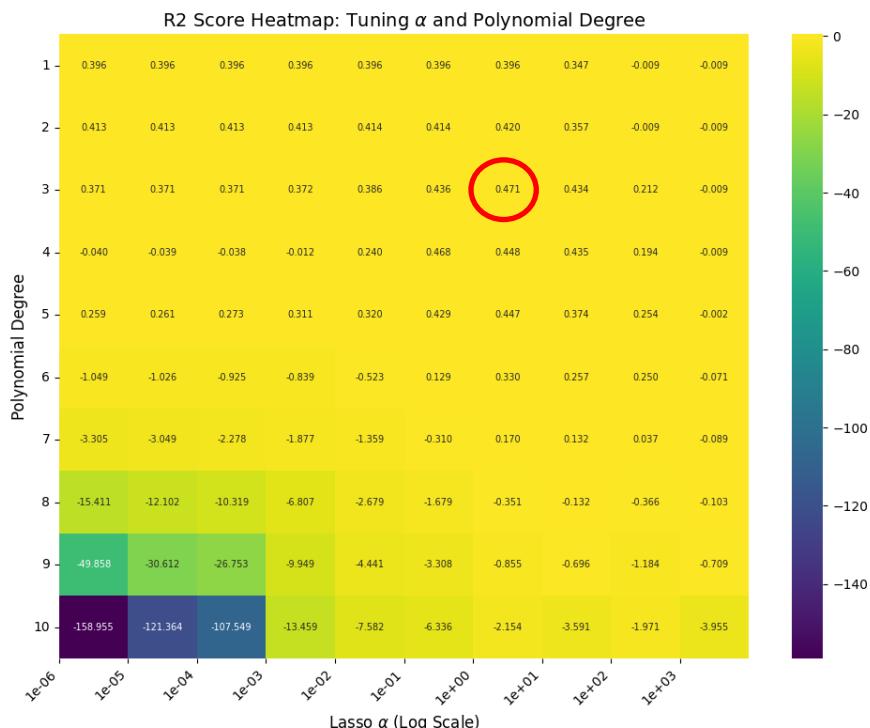
Best Polynomial Degree:	3
Best Alpha:	100
R2 Score on Training Set:	0.5365
R2 Score on Test Set:	0.5444
MAE on Training Set:	79.17
MAE on Test Set:	87.38
RMSE on Training Set:	101.38
RMSE on Test Set:	114.47

--- Lasso ---

Best Polynomial Degree:	3
Best Alpha:	1
R2 Score on Training Set:	0.5470
R2 Score on Test Set:	0.5639
MAE on Training Set:	78.91
MAE on Test Set:	86.09
RMSE on Training Set:	100.23
RMSE on Test Set:	111.99

--- Elastic Net ---

Best Polynomial Degree:	4
Best Alpha:	0.01
Best L1 Ratio:	0.33
R2 Score on Training Set:	0.6192
R2 Score on Test Set:	0.5285
MAE on Training Set:	72.14
MAE on Test Set:	88.20
RMSE on Training Set:	91.89
RMSE on Test Set:	116.45



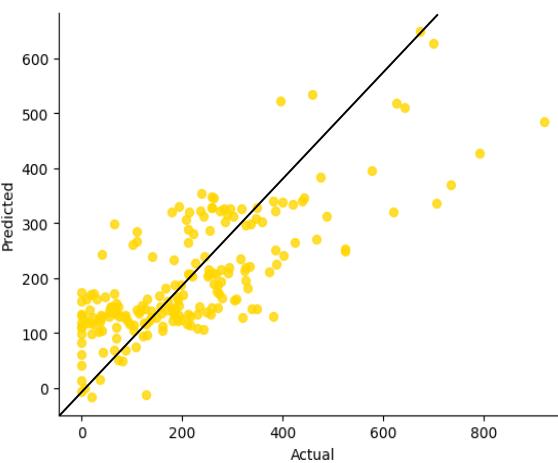
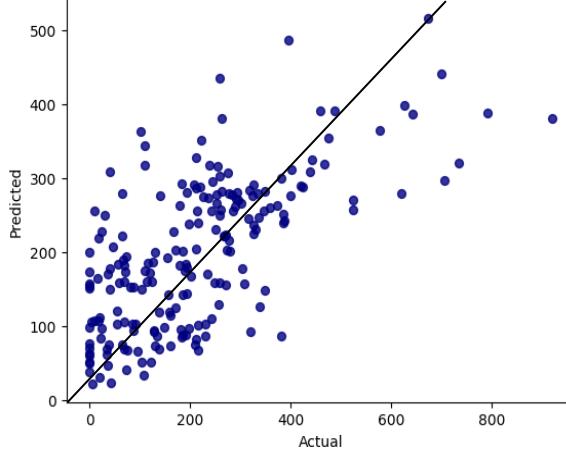
Lasso regression achieved the best performance on the test set, with the highest R^2 of 0.5639 using an alpha of 1 and a polynomial degree of 3.



Results from Models

Linear regression

$R^2 = 0.4315$

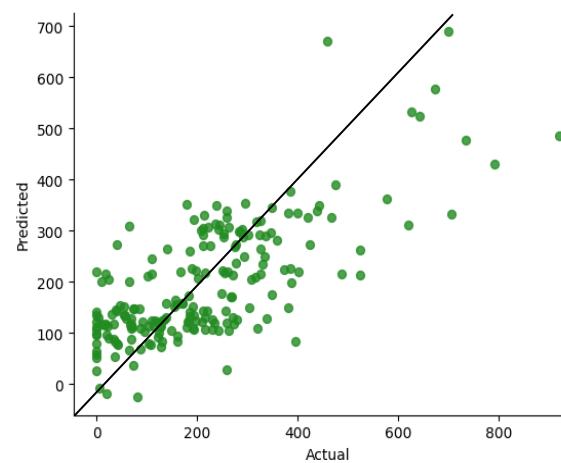
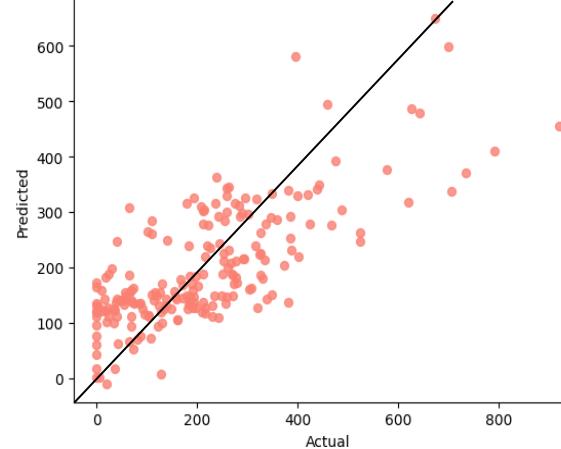


Lasso regression

$R^2 = 0.5639$

Ridge regression

$R^2 = 0.5444$



Elastic net regression

$R^2 = 0.5285$

- Lasso regression เป็นโมเดลทำนายปริมาณการขายที่ให้ค่า R^2 สูงสุด รวมถึง MAE และ RMSE น้อยที่สุด

ข้อเสนอแนะสำหรับการพัฒนาโมเดล

- อาจพิจารณาใช้ data ที่เป็น numerical แทน categorical เพื่อความแม่นยำในการทำนาย เช่น อุณหภูมิ ปริมาณฝน และ เบอร์เซ็นต์ส่วนลดค่าอาหาร
- ใช้การ split data ตามเวลา เนื่องจากข้อมูลเป็น time-series แทน random split
- พิจารณาโมเดล regression อื่น ๆ ร่วม เช่น kNN, SVM, และ อื่นๆ
- พิจารณาใช้การทำนายแบบ regression ร่วมกับการตีความปัจจัยที่ส่งผลต่อยอดขายจากโมเดลด้วย SHAP

Title: การวิเคราะห์ปัจจัยที่มีผลต่อยอดขายและการทำนายปริมาณการขายของร้านอาหารเพื่อวางแผนกลยุทธ์การตั้นยอดขาย

1. Background / Problem Statement

Background:

- ธุรกิจร้านอาหารต้องเผชิญความท้าทายในการบริหารจัดการยอดขาย การกำหนดราคา และการวางแผนโปรดิว咪ชัน ท่ามกลางปัจจัยภายนอกที่เปลี่ยนแปลง

Problem Statement:

- ขาดเครื่องมือคาดการณ์ยอดขายที่แม่นยำ
- การกำหนดราคาและโปรดิว咪ชันยังไม่องค์ข้อมูล
- ไม่ทราบปัจจัยที่ส่งผลต่อยอดขายและพฤติกรรมลูกค้า

2. Questions/Hypothesis

Research Questions:

- ปัจจัยใดบ้างที่มีผลกระทบต่อยอดขายของร้านอาหารอย่างไร
- สภาพอากาศ โปรดิว咪ชัน และเหตุการณ์พิเศษส่งผลต่อยอดขายอย่างไร
- ประเภทร้านอาหารและประเภทมื้ออาหารมีความสัมพันธ์กับยอดขายหรือไม่
- ผลกระทบจากการกำหนดราคาและโปรดิว咪ชันมีประสิทธิภาพเพียงใด
- ความแตกต่างระหว่างราคากลางกับราคากาจจุลจิจังส์ส่งผลต่อยอดขายอย่างไร
- โปรดิว咪ชันซ้ำๆเพิ่มยอดขายและผลกำไรได้จริงหรือไม่

3. Value Propositions

- ผู้ประกอบการร้านอาหาร: เข้าใจปัจจัยที่ส่งผลต่อยอดขายและพฤติกรรมลูกค้าซึ่งนำไปใช้ในการวางแผนกลยุทธ์ราคา โปรดิว咪ชัน และการบริหารเมนูอย่างมีประสิทธิภาพ
- นักการตลาด: ได้ข้อมูลเชิงลึกเกี่ยวกับประสิทธิภาพของโปรดิว咪ชันและปัจจัยภายนอกที่ส่งผลต่อการตัดสินใจซื้อของลูกค้าเพื่อวางแผนแคมเปญที่ตรงเป้าหมาย

4. Data Sources/Attributes

- Data Sources: Kaggle ([Link](#)) Restaurant Sales Report 2024-2025
- Attributes: 13
- Records: 10,000
- Target: ปริมาณการขาย (quantity_sold)
- Features:
ยอดขายวันก่อนหน้า (lag1), ราคาขาย (selling price),
สภาพอากาศ, มีโปรดิว咪ชัน, เหตุการณ์พิเศษ (event)

5. Analysis/Model Development

1. Analysis:

- Descriptive Statistics
- Correlation Analysis

2. Results:

- Data Visualization: Tableau
- Summary Statistics

3. Modeling (Supervised learning)

- linear regression
- regularized linear regression
(ridge, lasso, elastic net)

4. Model evaluation: R², MAE, RMSE

6. Findings and Insights

ปัจจัยที่ส่งผลต่อยอดขาย

สภาพอากาศแಡดให้ยอดขายสูงสุด 298 หน่วย (+13% จากวันฝน) โปรดิว咪ชันเพิ่มยอดขาย +92% และเหตุการณ์พิเศษเพิ่ม +29% Fine Dining มีกำไรสูงสุด 255 บาท แต่ขายน้อย ขณะที่ Food Stall ขายมาก 311 หน่วย แต่กำไรต่ำ 61 บาท อาหารเข้าข่ายได้มากกว่าเที่ยง-เย็น 85-119%

ประสิทธิภาพการกำหนดราคาและโปรดิว咪ชัน

ราคามีความสัมพันธ์เชิงลบกับยอดขาย ($r = -0.54$) การให้ส่วนลดเพิ่มยอดขาย +97% แต่ลดกำไรต่อหน่วย -55% โปรดิว咪ชันเพิ่มยอดขาย +92% แต่ลดกำไรต่อหน่วย -39% (จาก 121 เหลือ 74 บาท) อย่างไรก็ตามกำไรรวมยังเพิ่มขึ้นเนื่องจากปริมาณขายที่สูงขึ้นมาก

การทำนายปริมาณการขายของร้านอาหาร

Lasso regression เป็นโมเดลทำนายปริมาณการขายที่ให้ค่า R^2 สูงสุด รวมถึง MAE และ RMSE น้อยที่สุด แต่ค่า R^2 ที่ได้ยังต่ำ มีค่าเพียง 0.5639 ซึ่งอาจจะต้องใช้ SHAP มาช่วยดู Feature Importance ที่ส่งผลต่อโมเดลประกอบ และอาจพัฒนาโมเดลด้วยเทคนิค regression อื่น ๆ รวมถึงการแบ่ง data แบบ Time-series แทนการ random split เพื่อเพิ่มความแม่นยำของโมเดล

7. Recommendation/Action and Impact

- ปรับกลยุทธ์โปรดิว咪ชันให้มีประสิทธิภาพ
- บริหารจัดการตามสภาพอากาศและเหตุการณ์พิเศษ
- Menu Engineering และ Dynamic Pricing
- กระจายยอดขายตลอดทั้งวัน



Link Github Click

ThitiwutM / Restaurant-data-insights-and-prediction

Type / to search

Code Issues Pull requests Actions Projects Wiki Security Insights Settings

Files

main Go to file

DS514 Quantity_sold prediction.i... README.md data distribution.jpg model results.jpg project scope.jpg restaurant_dataset.csv

ThitiwutM add picture 7d50603 · 12 minutes ago History

Preview Code Blame 56 lines (31 loc) · 7.4 KB

Restaurant-data-insights-and-prediction

This is a term project for the DS512/513/514/515 Data Analytics and Data Science course at SWU, Thailand.

The project aims to explore insights from restaurant sales data and identify the key factors influencing sales volume. In addition, we developed predictive models for quantity sold using linear regression and regularized linear regression techniques (Ridge, Lasso, and Elastic Net) to support restaurants in improving their performance and developing effective strategies to enhance sales.

The process includes data type checking, data cleaning, exploratory data analysis (EDA), data visualization and dashboard creation, feature selection, data pre-processing before modeling, data pipeline development, model building, and model evaluation.

โครงการนี้เป็นโครงการของรายวิชา DS512/513/514/515 Data Analytics and Data Science ระดับปริญญาโท มหาวิทยาลัยศรีนครินทรวิโรฒ

โครงการนี้มีวัตถุประสงค์เพื่อสำรวจข้อมูลยอดขายของร้านอาหารและหาปัจจัยสำคัญที่มีผลต่อปริมาณการขาย นอกจากรายได้พัฒนาโน้ตเดลสำหรับการทำนายปริมาณการขาย (Quantity sold) โดยใช้เทคนิค Linear Regression และ Regularized Linear Regression (Ridge, Lasso และ Elastic Net) เพื่อสนับสนุนร้านอาหารในการปรับปรุงประสิทธิภาพและพัฒนากลยุทธ์ที่เหมาะสมในการเพิ่มยอดขาย

กระบวนการทำงานประกอบด้วย การตรวจสอบประเภทข้อมูล การทำความสะอาดข้อมูล การวิเคราะห์ข้อมูลเบื้องต้น (EDA) การสร้างภาพข้อมูลและแดชบอร์ด การคัดเลือกตัวแปรสำหรับโน้ตเดล การเตรียมข้อมูลก่อนสร้างโน้ตเดล การพัฒนา data pipeline การสร้างโน้ตเดล และการประเมินผลโน้ตเดล